19

Apache Airflow từ số 0

DAG · operator · scheduling · backfill

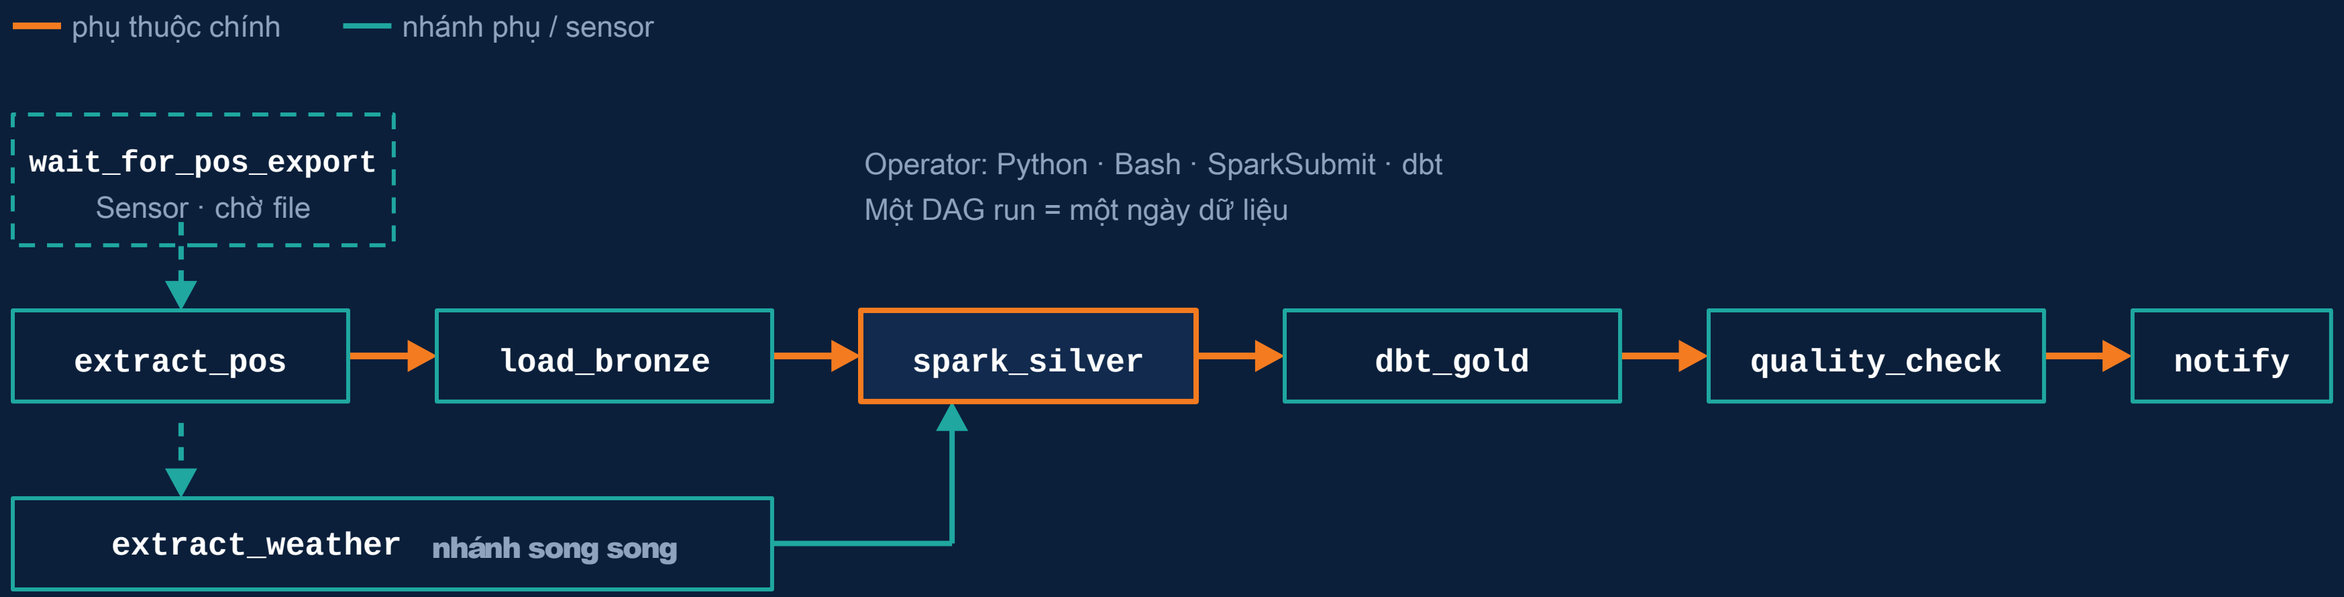
Hôm nay mình nói gì

1. Orchestration là gì
2. DAG, task, operator, sensor · TaskFlow API
3. Scheduling, catchup, backfill
4. XCom
5. Airflow vs Dagster vs Prefect

Orchestrator không xử lý dữ liệu

- Quyết định cái gì chạy, khi nào, sau cái gì
- Chạy lại khi lỗi
- Báo khi hỏng
- Dữ liệu chạy ở Spark / dbt / Python, không ở Airflow

DAG của dự án



Mũi tên = phụ thuộc, không phải dữ liệu.

Từ vựng

DAG	đồ thị công việc
Task	một ô
Operator	loại việc: Bash, Python, Spark, dbt
Sensor	task chờ điều kiện
DAG run	một lần chạy cho một logical date

TaskFlow API

```
from airflow.decorators import dag, task

@dag(schedule="0 2 * * *", start_date=datetime(2026, 11, 1), catchup=False)
def coffee_daily():
    @task
    def extract_pos(ds: str) -> str:
        return pos.extract(day=ds)          # trả về đường dẫn bronze
    @task
    def spark_silver(path: str) -> int:
        return spark.submit("silver_pos.py", path)
    @task
    def dbt_gold(rows: int):
        bash("dbt build --select +fact_sales")
    dbt_gold(spark_silver(extract_pos()))
coffee_daily()
```

Code Python thường, Airflow lo phần còn lại. Gọi lồng nhau = phụ thuộc.

Logical date — cái dễ nhầm nhất

- DAG chạy 2:00 ngày 2/11, xử lý dữ liệu ngày 1/11
- `logical_date` = 1/11, không phải 2/11
- Dùng `{{ ds }}` thay vì ~~`today()`~~
- Nhờ vậy chạy lại ngày cũ vẫn đúng

Catchup và backfill

- `catchup=True` → chạy bù mọi ngày từ start_date
- **Nguy hiểm khi bật nhầm**
- **Backfill có chủ đích:** `airflow dags backfill -s 2026-10-01 -e 2026-10-30 coffee_daily`
- **Pipeline phải idempotent (video 7) mới backfill được**

Gọi Spark và dbt

```
spark_silver = SparkSubmitOperator(
    task_id="spark_silver",
    application="jobs/silver_pos.py",
    application_args=["--day", "{{ ds }}"],
    conn_id="spark_default",
)

dbt_gold = BashOperator(
    task_id="dbt_gold",
    bash_command="dbt build --select +fact_sales --vars 'day: {{ ds }}'",
    cwd="/opt/dbt",
)

extract_pos >> load_bronze >> spark_silver >> dbt_gold >> quality_check >> notify
```

Ngày đi qua template, không đi qua code. Backfill chỉ cần đổi ds.

XCom: nhỏ thôi

- Truyền số dòng, đường dẫn, trạng thái giữa task
- Không truyền DataFrame
- Dữ liệu lớn đi qua lake, task chỉ truyền đường dẫn

Airflow vs Dagster vs Prefect

	Airflow series dùng, CV cần	Dagster	Prefect
Mô hình	Task	Asset	Flow
Cộng đồng & tuyển dụng VN	Lớn nhất	Đang lên	Vừa
UI	Đủ dùng, Graph + Gantt	Lineage asset đẹp	Gọn, cloud-first
Local dev	Nặng, cần Docker	Nhẹ, pytest được	Nhẹ nhất
Chọn khi	Chuẩn ngành, nhiều integration	Thích asset-centric, team mới	Python-first đơn giản

Lỗi hay gặp

SAI	ĐÚNG
~~Xử lý Pandas trong PythonOperator trên worker Airflow~~	~~Đẩy sang Spark / dbt~~
~~datetime.now() trong task~~	Logical date
~~catchup=True với start_date 2 năm trước~~	False, backfill tay
~~Một DAG 80 task~~	Tách theo domain, dùng dataset trigger
~~retries=0~~	retries=2, retry_delay

Lab #19 — DAG chạy toàn bộ batch pipeline + backfill 30 ngày

1. Viết DAG nối Lab #07 → #09 → #10 → #12
2. Chạy tay 1 ngày, xem Graph view và log
3. Cố ý làm dbt test fail, xem task đỏ, downstream skip
4. Backfill 30 ngày, theo dõi Gantt
5. Thêm Slack / Email notify khi fail

KẾT QUẢ MONG ĐỢI

30 DAG run xanh

Gold có đủ 30 ngày, không trùng

CÂU HỎI PHỎNG VẤN #19

Airflow có nên xử lý dữ liệu không?

Orchestrate, không compute; lý do: scale, tách lỗi, chi phí worker.

VIDEO TIẾP THEO

20

Data Quality: Great Expectations, dbt test, contract — chặn dữ liệu bẩn từ gốc

Thứ Sáu 8/1 · 19:00

Đăng ký