20

Data Quality

Great Expectations · dbt test · data contract

Hôm nay mình nói gì

1. Vì sao pipeline xanh mà số sai · 6 chiều chất lượng
2. Kiểm tra ở đâu trong pipeline
3. Great Expectations
4. Data contract
5. Circuit breaker & alert

Pipeline xanh, số sai

- Nguồn đổi đơn vị tiền
- Cột mới toàn null
- Dữ liệu đến thiếu một cửa hàng
- Trùng do retry
- Không test nào bắt → sếp bắt

6 chiều chất lượng

Completeness

đủ dòng, không null

Uniqueness

không trùng khoá

Validity

đúng kiểu, đúng miền

Accuracy

khớp thực tế

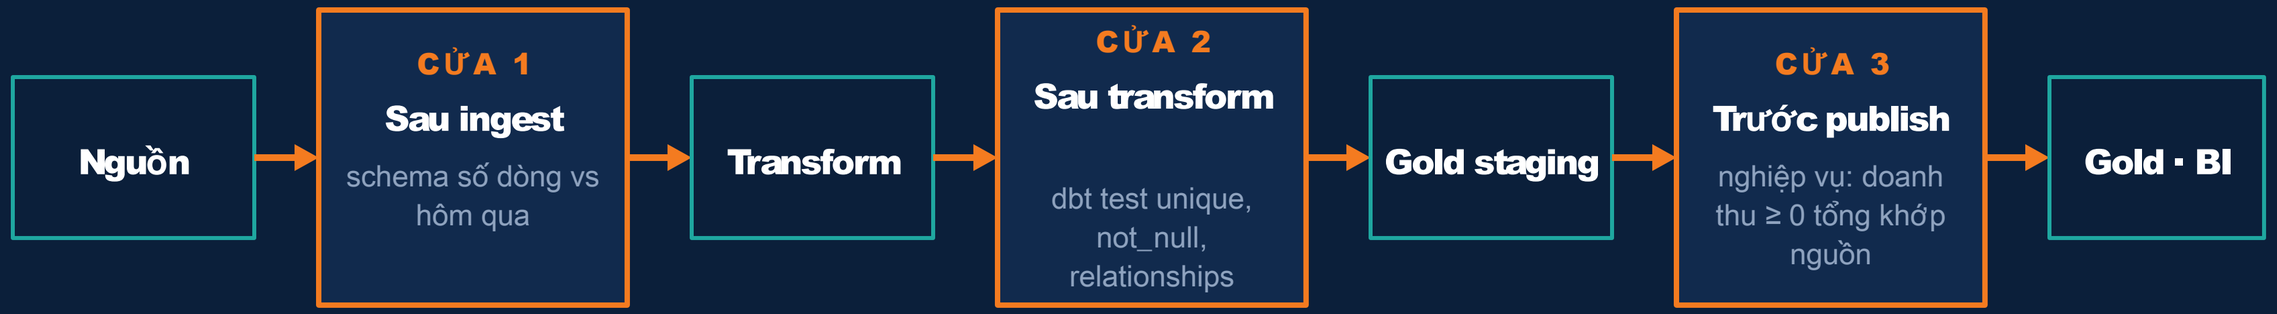
Consistency

khớp giữa bảng

Timeliness

đến đúng giờ

Kiểm tra ở 3 cửa



Bắt càng sớm, sửa càng rẻ.

Great Expectations suite

```
import great_expectations as gx

batch = ctx.data_sources.get("lake").get_asset("silver_pos").get_batch(day=ds)
yesterday = row_count("silver_pos", day=ds_minus_1)

suite = gx.ExpectationSuite("silver_pos_daily")
suite.add(gx.expectations.ExpectColumnValuesToNotBeNull(column="store_id"))
suite.add(gx.expectations.ExpectColumnValuesToBeUnique(column="sale_id"))
suite.add(gx.expectations.ExpectColumnValuesToBeBetween(
    column="amount", min_value=0, max_value=5_000_000))
suite.add(gx.expectations.ExpectTableRowCountToBeBetween(
    min_value=int(yesterday * 0.7), max_value=int(yesterday * 1.5)))

result = batch.validate(suite); assert result.success, result.describe()
```

Kiểm tra tương đối với hôm qua bắt được sự cố thiếu dữ liệu.

dbt test vs Great Expectations vs Soda

	dbt test	Great Expectations	Soda
Chạy ở đâu	Trong dbt	Python, mọi nơi	YAML, CLI
Điểm mạnh	Gần SQL, dễ	Phong phú, data docs	Đơn giản, SaaS
Dùng trong series	Gold · cửa 2	Silver · cửa 1, 3	Nhắc đến

Data contract

- Thoả thuận giữa đội tạo dữ liệu và đội dùng
- Schema + ý nghĩa + SLA + owner
- Viết thành file YAML trong repo nguồn
- CI của backend chạy kiểm tra contract khi đổi schema
- Video 16 đã thấy vì sao cần

contracts/orders.yaml

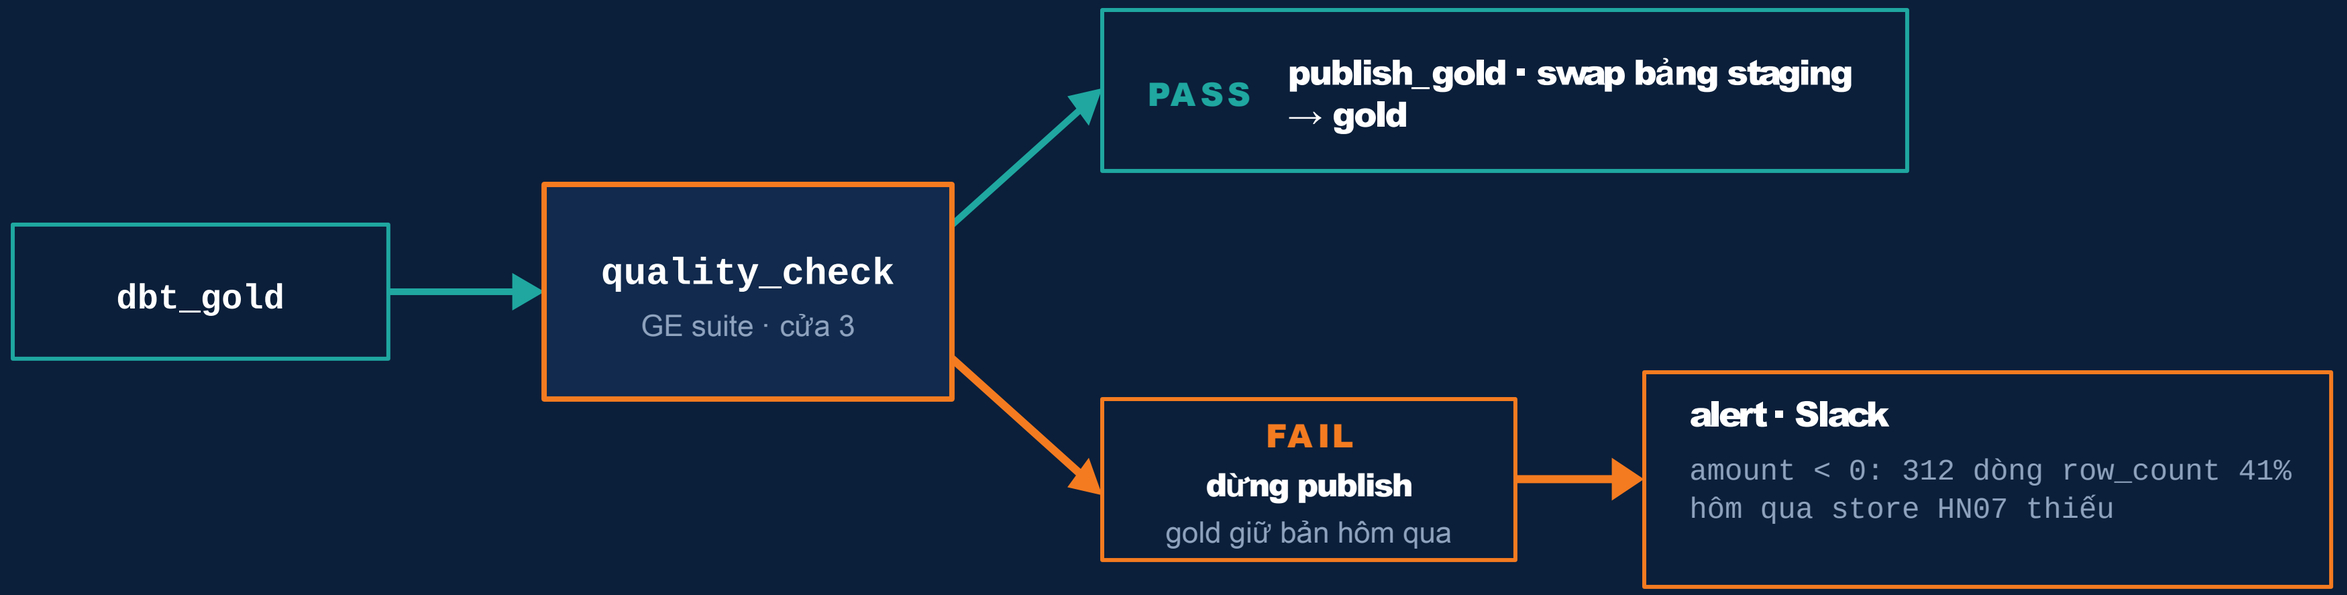
```yaml
table: public.orders
owner: backend-team          # ai chịu trách nhiệm
fields:
  - {name: order_id,  type: bigint,    required: true, description: "khoá chính"}
  - {name: store_id,  type: string,    required: true, description: "mã cửa hàng"}
  - {name: amount,    type: decimal,   required: true, description: "VND, sau giảm giá"}
  - {name: status,    type: string,    enum: [pending, paid, cancelled]}
  - {name: updated_at, type: timestamp, required: true}
sla:
  freshness: 15m             # dữ liệu không trễ quá 15 phút
  availability: "99.5%"
breaking_changes:
  policy: notify-30-days     # xoá/đổi kiểu cột phải báo trước
  allowed: [add_nullable_column]
```

Sống trong repo backend, CI của họ chạy khi đổi migration.

Schema validation vs Data contract

	Schema validation	Data contract
Kiểm tra gì	Kiểu, cột	Kiểu + ngữ nghĩa + SLA + trách nhiệm
Ai sở hữu	Consumer (DE)	Producer (backend)
Khi nào chạy	Lúc đọc, đã quá muộn	Lúc producer thay đổi, trong CI
Ngăn được gì	Pipeline đọc file sai kiểu	Schema vỡ trước khi tới pipeline

Circuit breaker trong DAG



Thà báo cáo cũ còn hơn báo cáo sai.

Lỗi hay gặp

SAI	ĐÚNG
~~Test chỉ not_null~~	Thêm kiểm tra tương đối: volume, phân phối
~~Alert mọi thứ~~	Severity warn vs error
~~Test ở gold rồi mới biết~~	3 cửa
~~Contract chỉ là tài liệu~~	Chạy trong CI

Lab #20 — Chặn dữ liệu bẩn

1. Thêm GE suite vào task quality_check của DAG #19
2. Bơm dữ liệu lỗi: `coffeegen pos --corrupt amount-negative,store-missing`
3. Xem DAG dừng đúng cửa, gold giữ bản cũ
4. Viết contract YAML cho orders, thêm script kiểm tra vào CI của repo
5. Đổi schema phá hợp đồng, xem CI đỏ

KẾT QUẢ MONG ĐỢI

2 lỗi bị chặn ở 2 cửa khác nhau

CI đỏ khi phá contract

CÂU HỎI PHỎNG VẤN #20

Data contract khác schema validation gì?

Trách nhiệm chuyển sang producer; có SLA, owner, chạy khi thay đổi.

VIDEO TIẾP THEO

21

Data Observability & Lineage: biết pipeline hỏng trước khi sếp biết

Thứ Ba 12/1 · 19:00

Đăng ký