22

CI/CD & Infrastructure as Code

GitHub Actions + Terraform cho data pipeline

Hôm nay mình nói gì

1. Vì sao DE cần CI/CD · Git flow cho data
2. Test pipeline khác test code
3. dbt CI
4. Terraform cho lake
5. Môi trường dev / staging / prod

Không CI/CD thì

- Sửa DAG trên server bằng vim
- "Hôm qua ai đổi gì?"
- Không rollback được
- Môi trường dev khác prod
- Mọi thay đổi là một lần hồi hộp

Git flow cho DE

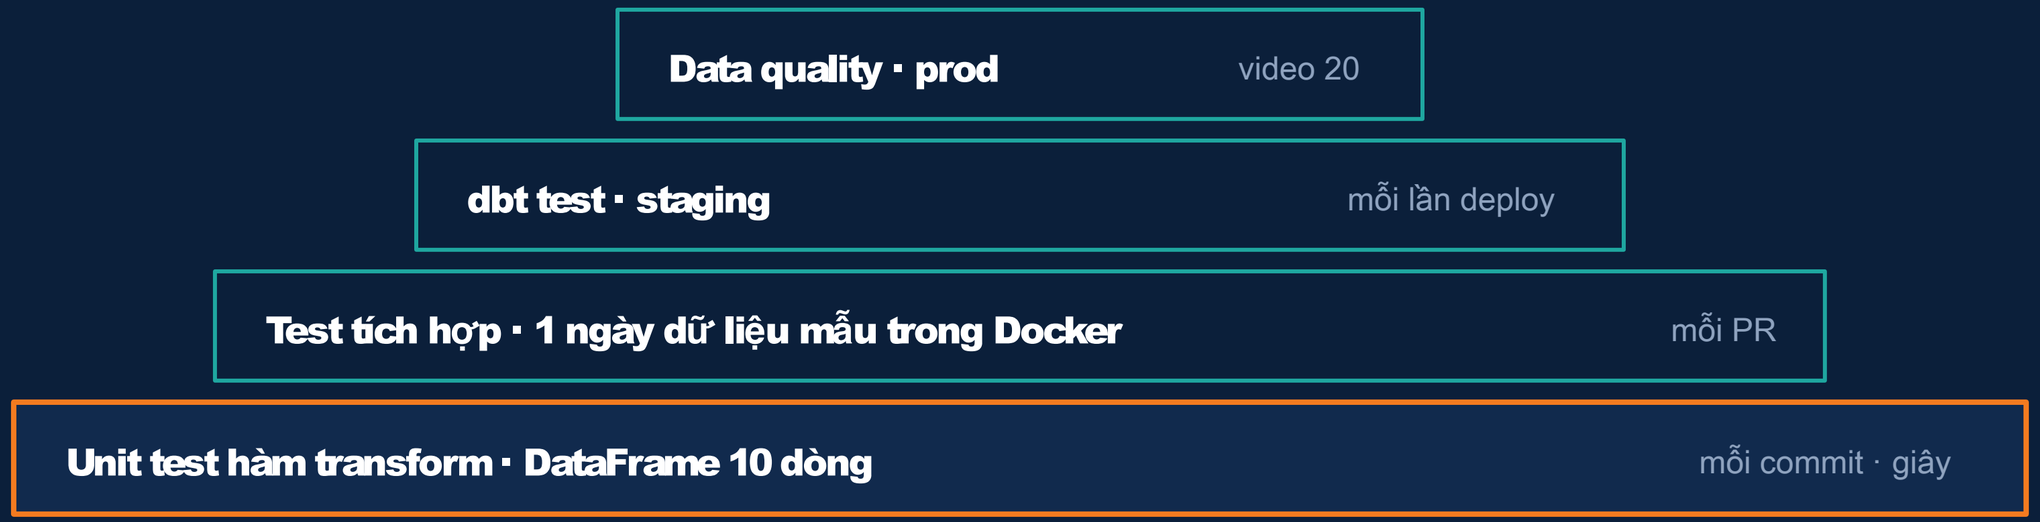


Mọi thứ chạy trong production đều từng qua một PR.

Test code vs Test pipeline dữ liệu

	Test code	Test pipeline dữ liệu
Đầu vào	Cố định	Dữ liệu thay đổi mỗi ngày
Kiểm tra gì	Logic	Logic + dữ liệu + schema
Môi trường	Mock	Dữ liệu mẫu thật, nhỏ
Khó nhất	Edge case	Dữ liệu bẩn thật

Tháp test cho pipeline



Nhiều ở đáy, nhanh và rẻ; ít ở đỉnh, chậm và thật.

.github/workflows/ci.yml

```yaml
name: ci
on: [pull_request]
jobs:
  test:
    runs-on: ubuntu-latest
    steps:
      - uses: actions/checkout@v4
      - uses: actions/setup-python@v5
        with: {python-version: "3.12", cache: pip}
      - run: pip install -e ".[dev]"
      - run: ruff check . && ruff format --check .
      - run: pytest tests/ -q
      - run: cd dbt && dbt deps && dbt build --target ci   # DuckDB, dữ liệu mẫu
```

DuckDB cho CI chạy không cần service, dưới 2 phút.

dbt CI nâng cao

- Slim CI — chỉ build model đổi và downstream: `--select state:modified+`
- Schema riêng cho mỗi PR, xoá khi merge
- So kết quả PR với prod (data diff)

Infrastructure as Code

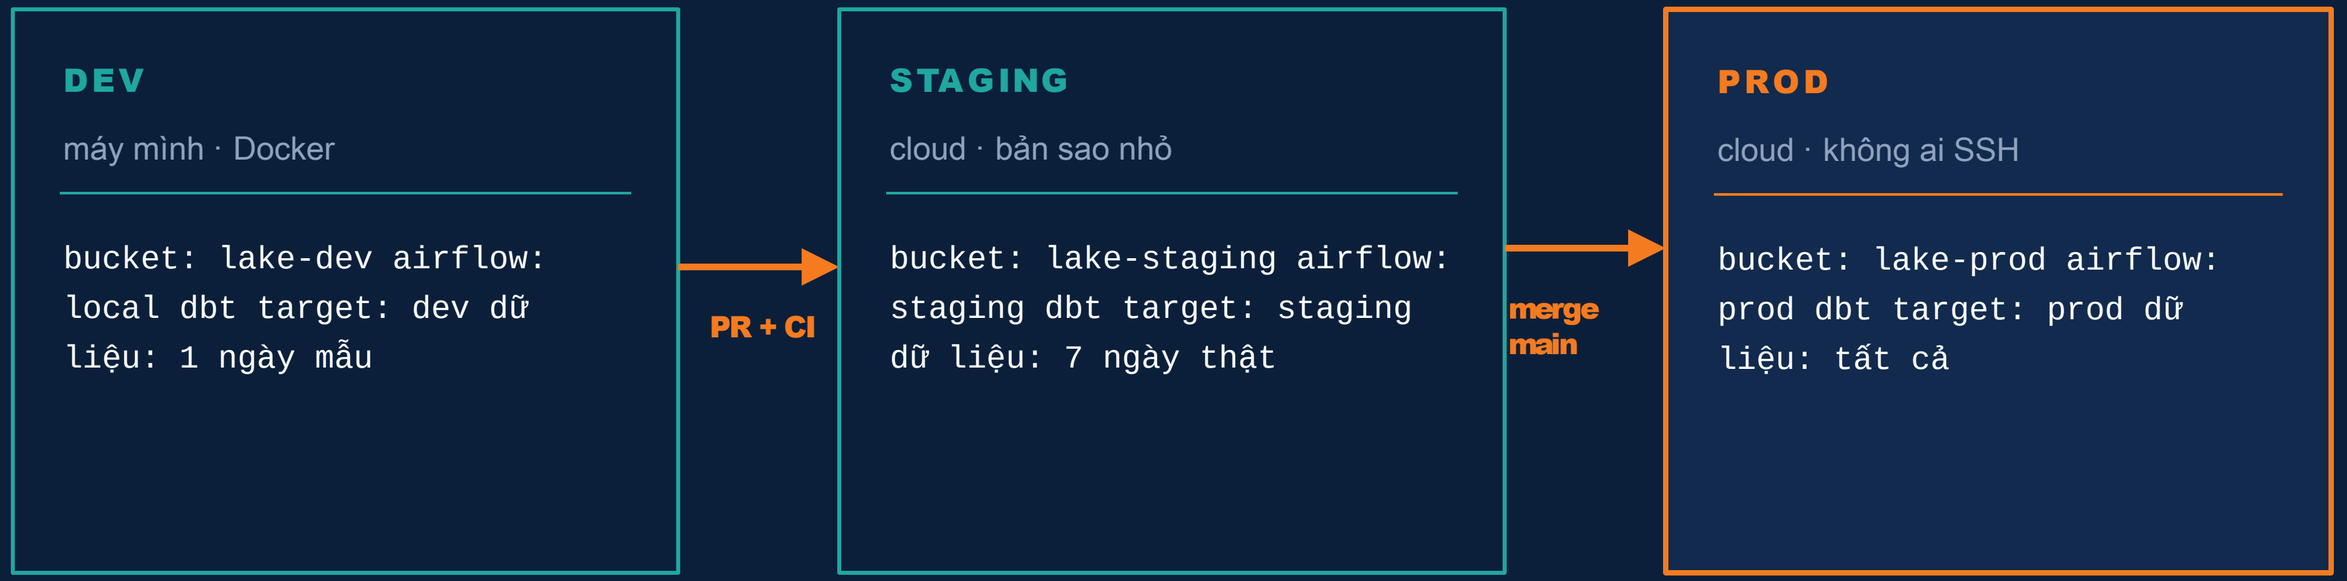
- Bucket, catalog, IAM, Kafka topic, Airflow connection đều là code
- `terraform plan` trong PR để reviewer thấy sẽ đổi gì
- State lưu từ xa (S3 + lock)
- Không click console trong prod

infra/lake.tf

```
resource "aws_s3_bucket" "lake" { bucket = "coffee-lake-${var.env}" }
resource "aws_s3_bucket_public_access_block" "lake" {
  bucket = aws_s3_bucket.lake.id   block_public_acls = true   restrict_public_buckets = true
}
resource "aws_s3_bucket_lifecycle_configuration" "lake" {
  bucket = aws_s3_bucket.lake.id
  rule { id = "bronze"  filter { prefix = "bronze/" }  status = "Enabled"
         transition { days = 30  storage_class = "STANDARD_IA" }  expiration { days = 365 } }
}
resource "aws_glue_catalog_database" "silver" { name = "silver_${var.env}" }
resource "aws_iam_role" "ingest_job" { name = "ingest-${var.env}"  assume_role_policy = local.assume }
data "aws_iam_policy_document" "ingest" {
  statement { actions = ["s3:PutObject", "s3:GetObject"]
    resources = ["${aws_s3_bucket.lake.arn}/bronze/*", "${aws_s3_bucket.lake.arn}/silver/*"] }
}
```

Job ingest chỉ được ghi bronze/silver. Lifecycle rule từ video 9 giờ là code.

dev / staging / prod



Khác nhau ở biến, không ở code.

Lỗi hay gặp

SAI	ĐÚNG
~~Test bằng cách chạy trên prod rồi xem~~	Dữ liệu mẫu + staging
~~Terraform state trong repo~~	Remote state có lock
~~Secret trong workflow YAML~~	GitHub Secrets / OIDC
~~CI chạy 40 phút~~	Slim CI, DuckDB, cache

Lab #22 — CI cho dbt, Terraform cho lake

1. Thêm workflow CI vào repo, mở PR đổi 1 model, xem CI chạy
2. Cố ý phá test, xem PR đỏ
3. Viết Terraform cho bucket + IAM (AWS thật hoặc LocalStack)
4. `terraform plan` trong PR, apply sau merge
5. Tạo target staging cho dbt

KẾT QUẢ MONG ĐỢI

PR có check xanh / đỏ đúng

Bucket tạo bằng code với lifecycle rule từ #09

CÂU HỎI PHỎNG VẤN #22

Test pipeline dữ liệu khác test code thường ở đâu?

Đầu vào thay đổi; cần dữ liệu mẫu thật, test schema và phân phối.

VIDEO TIẾP THEO

23

Chi phí & bảo mật dữ liệu: FinOps, PII, access control

Thứ Ba 19/1 · 19:00

Đăng ký